

Faculdade de Letras da Universidade do Porto

Mestrado em Sistemas de Informação Geográfica e Ordenamento do Território

Deteção Remota Aplicada ao Ordenamento do Território

Ano Letivo 2020/2021

PROCESSAMENTO E ANÁLISE DE IMAGENS E DADOS SATÉLITE, NO CONCELHO DE MONÇÃO

Docentes:

Ana Cláudia Moreira Teodoro

José Augusto Alves Teixeira

Lia Bárbara Cunha Barata Duarte

Discentes:

Gabriela Franco Ribeiro

Joana Filipa Cunha Feliz dos Santos

José Henrique Campos da Costa

Índice

1- Introdução e objetivos	3
2- Caracterização da área de estudo	4
3- Metodologia	6
4- Resultados	7
4.1-Cálculo do NDVI para Sentinel/Landsat	7
4.2- Classificação de imagem	11
4.3- Avaliação da Exatidão da Imagem	14
5- Conclusão	16
6- Bibliografia	17

Índice de imagens

Figura 1- Mapa de Enquadramento.	4
Figura 2 - Hipsometria e rede hidrográfica do concelho de Monção.....	5
Figura 3 – A) NDVI de inverno proveniente de imagens Sentinel; B) NDVI de verão proveniente de imagens Sentinel.....	9
Figura 4- A) NDVI de inverno proveniente de imagens Landsat; B) NDVI de verão proveniente de imagens Landsat.	10
Figura 5 - Classificação supervisionada da imagem de inverno.....	11
Figura 6- Imagem de combinação RGB de inverno.	12
Figura 7 - Classificação supervisionada da imagem de verão.	13
Figura 8 - Imagem de combinação RGB de verão.....	13
Figura 9 - Matriz de erro relativa ao inverno.....	15
Figura 10 - Matriz de erro relativo ao verão.....	16

1- Introdução e objetivos

O estudo incide na utilização de imagens de dois satélites distintos, desta forma é necessário consolidar alguns conceitos essenciais para a compreensão do mesmo.

“A observação da Terra (EO - Earth Observation) por sensores remotos corresponde a um ramo particular da DR, que permite a interpretação e o conhecimento dos fenómenos na superfície da Terra, através da análise e interpretação das medições da REM refletida ou emitida por objetos que se encontram na terra, mar ou atmosfera do nosso planeta, e adquiridas por sensores a bordo de aviões ou em órbita (satélites EO)” (Lira et al., 2016, p.26).

O Programa Landsat constitui-se como uma atual fonte de imagens satélite multiespectrais, sendo que estas podem ser aplicadas em vários campos, desde geologia, gestão de recursos, geografia, qualidade da água, até outros tipos de aplicação. Este apresenta uma série de dados contínua, desde 1972, sendo o satélite mais recente, o Landsat 8, que inclui os sensores OLI/TIRS. Estes sensores contêm 3 bandas, azul, SIR (cirrus) e quality assessment band (OLI) e duas bandas termais (TIRS). O Landsat localiza-se na órbita polar, ou seja, uma órbita de altitude baixa (917km). Esta posteriormente irá influenciar os seus tipos de resolução, espacial, temporal, espectral e radiométrica. Relativamente à resolução espacial, que é influenciada pela altura do satélite na órbita e está dependente do campo instantâneo de visão e que posteriormente resulta no tamanho do pixel da imagem na superfície. O Landsat contém bandas de 30m (bandas 1 a 7 e 9), 15m (banda 8), 100m (bandas 10 e 11). No que toca à resolução temporal, isto é, a frequência que este recolhe imagens de uma determinada área, é de 16 dias de órbita. Quanto à resolução espectral, cujo descreve a habilidade de um sensor definir a “fineza” de comprimento de onda. A resolução radiométrica, que descreve a habilidade do sensor discriminar diferenças muito pequenas de energia, expressa em bits que corresponde ao nível de claridade, é de 16 bits.

O satélite Sentinel pertence ao programa Copernicus, sendo o Sentinel 6 o mais recente. O Sentinel apresenta dados relativos às imagens radar da Terra e oceano, imagens óticas MR, radar e altimetria para serviços marinhos e terrestres, assim como também apresenta domínios no que toca à monitorização da composição atmosférica. O satélite 2-A lançado em 2015 é constituído por 13 bandas (4 bandas com resolução de 10 m, 6 bandas com resolução de 20m e 3 bandas com resolução de 60m), este é mais relevante que o Landsat 8 para a elaboração de mapas de cobertura terrestre. Já o Sentinel 2-B lançado em 2017, este apresenta uma resolução temporal menor (5 dias) pois é mais desfasada que o satélite anterior (10 dias), mas pelo contrário tem uma resolução espacial maior.

O uso de dois satélites distintos tem como finalidade conseguir comparar as diferenças entre estes e o cálculo de índices ambientais em épocas distintas (Primavera/Verão; Outono/Inverno). Os índices não são medidos pelos sensores dos satélites, mas sim calculados

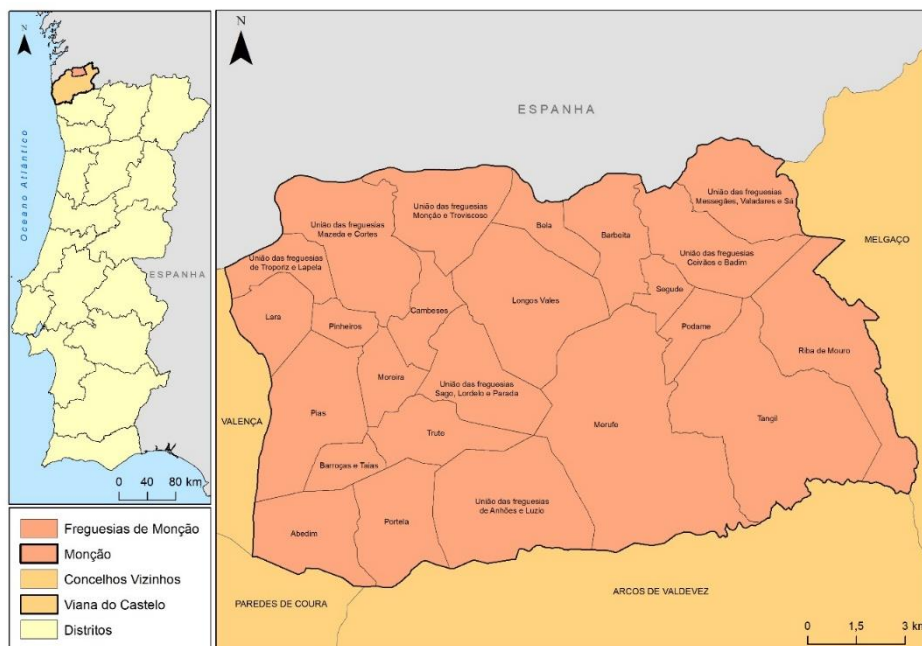
posteriormente. Estes são criados a partir da informação contida nas bandas com uma determinada fórmula como vai ser possível observar durante este trabalho.

Como objetivos para este trabalho é pretendido comparar as diferentes imagens obtidas através de satélites distintos, isto de modo a compreender dissemelhanças neles contidas e as suas múltiplas distinções no que toca ao tipo de resolução espacial. É também intencionado, o cálculo do NDVI, de modo a entender como varia a atividade fotossintética entre duas épocas distintas (Inverno/Verão). Por fim, é objetivado executar uma classificação de imagem de modo a pôr em prática as etapas que foram lecionadas, desde o pré processamento de imagem, aplicação do algoritmo, avaliação da exatidão do processo à elaboração de um mapa do uso do solo com base na imagem de satélite.

2- Caracterização da área de estudo

A área de estudo definida para este trabalho é o concelho de Monção, distrito de Viana do Castelo. Geograficamente este município é limitado a norte pelo país vizinho, a Espanha, tendo o Rio Minho como barreira física marcante, a leste pelo concelho de Melgaço, a oeste por Valença, a sudoeste pelos Arcos de Valdevez e a sul por Paredes de Coura.

O concelho de Monção abarca cerca de 19179 habitantes (segundo os censos de 2011), assim como compreende uma superfície de cerca 211km² (CM Monção, 2021). Este é constituído por 24 freguesias sendo elas Abedim, União das freguesias de Anhões e Luzio, Barbeita, União das freguesias de Barroças e Taias, Bela, Cambeses, União das freguesias de Ceivães e Badim, União das freguesias de Lapela e Troporiz, Lara, Longos Vales, União das freguesias de Mazedo e Cortes, Merufe, União das freguesias de Messegães, Valadares e Sá, União das freguesias de Monção e Troviscoso, Moreira, Pias, Pinheiros, Podame, Portela, Riba de Mouro, União das freguesias de Sago, Lordelo e Parada, Segude, Tangil e Trute.



Fonte: CAOP (2019); DivaGIS;

Figura 1- Mapa de Enquadramento.

Para definir a região ao nível das suas características, podemos afirmar que uma percentagem muito expressiva do solo é ocupada por floresta e matos, tendo como principais contrapontos apenas o centro da vila de Monção e algumas outras pequenas aglomerações populacionais, muito pouco expressivas.

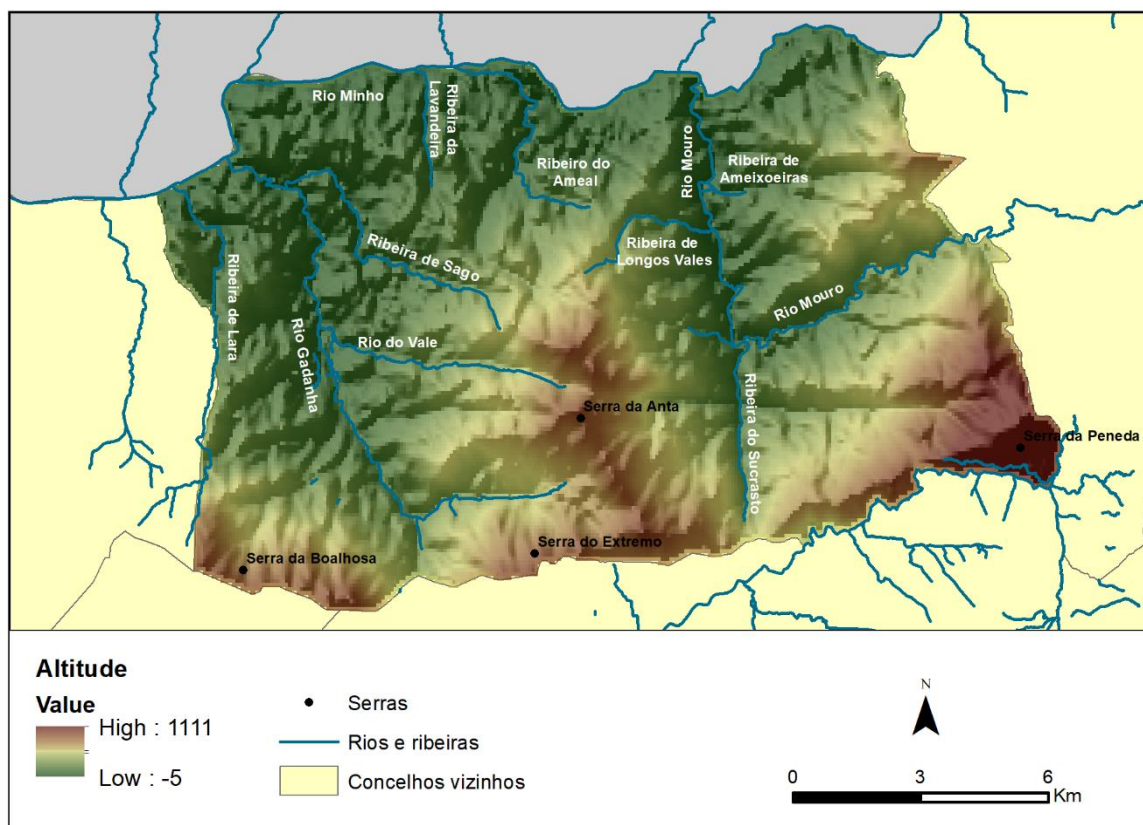


Figura 2 - Hipsometria e rede hidrográfica do concelho de Monção.

Em relação às estruturas físicas do concelho, no que concerne à topografia, pode-se identificar pela figura 2, a existência de elevações na área de estudo com alguma relevância, como a Serra da Peneda. As diferenças de terreno visíveis estão assim por vezes associadas ao escavamento natural que os rios fazem ao longo do seu percurso natural.

Ao nível dos recursos hídricos, o concelho de Monção tem ao seu dispor um conjunto de rios e ribeiras que cobrem o território. Na margem esquerda do rio Minho pode-se realçar, pela sua posição mais marcante na área, o Rio Moura e o Rio Gadanha, seus afluentes, como pertencentes à sua bacia. Verifica-se ainda a existência de outras bacias hidrográficas de menor dimensão. Noutra dimensão identifica-se ainda dois ribeiros importantes, a ribeiro de Lara e o Ribeiro de Sucrasto.

3- Metodologia

Para a elaboração da análise aos diferentes tipos de imagens e dados criados, foi necessário realizar alguns processos a fim de se atingirem os objetivos pretendidos. Numa primeira fase foi preciso fazer a escolha de qual área se iria trabalhar, para posteriormente se obter as imagens para a localização correta. Num segundo momento procedeu-se então à exportação das imagens de satélite, sendo necessário utilizar duas plataformas online, gratuitas, pertencentes aos dois tipos de satélites. As imagens escolhidas obedeceram a critérios previamente definidos, isto é, para cada satélite duas imagens e ao mesmo tempo de épocas do ano desfasadas, estações diferentes.

As imagens provenientes do programa Landsat, disponíveis no site da USGS, foram de dia 23 de fevereiro (inverno), e de 9 de julho (verão). Por oposição as relativas ao programa Copernicus, disponíveis no site do Copernicus Open Access Hub, tendo como satélite o Sentinel 2-A, são de dia 22 de fevereiro (inverno), e 11 de julho (verão). Neste passo teve-se em atenção a proximidade de datas entre os diferentes tipos, para se poder da melhor maneira analisar diferenças.

No seguimento dos processos anteriores, e já numa fase de tratamento da informação recolhida, com o auxílio da software QGIS, iniciou-se o corte das imagens pela área de estudo pretendida. Para esta tarefa foi necessário primeiramente a Shapefile da CAOP 2019 e a ferramenta *select by attributes*, para ficar apenas com a área de estudo e exportá-la. Após isto realizou-se este procedimento para todas as imagens e suas bandas para que estas fiquem só com a informação necessária.

Seguidamente foi realizado um índice ambiental com o intuito de analisar as características principais da área de estudo, ao nível da sua cobertura vegetal. Nessa medida foi necessário com o auxílio da *calculadora de rasters*, para cada índice realizado, introduzir as bandas e executar o cálculo, seguindo-se com a exportação de cada resultado numa nova *shapefile*.

Para a realização da classificação da imagem, foi utilizado o software ArcGis Pro onde se utilizou um conjunto de ferramentas para fazer o procedimento. Primeiramente, fez-se uma combinação RGB (banda vermelho, verde e azul) de modo a obter uma imagem de cor verdadeira para cada estação do ano com a ferramenta *Composite bands*. De seguida, usou-se a ferramenta *Classification Wizard* para começar a fazer a classificação, onde temos de ajustar alguns parâmetros como o tipo de classificação (supervisionada ou não supervisionada), se é baseado em píxel ou em objeto, o esquema de classes e tipo de classificador. No caso, escolheu-se uma classificação supervisionada, baseada em píxeis, o esquema de classes padrão e o classificador *Maximum Likelihood* ou em português, método da máxima verosimilhança. Como se trata de uma

classificação supervisionada, além de determinar parâmetros, é necessário determinar áreas de treino das classes pretendidas, que foram definidas não só através pela combinação RGB, mas também com auxílio da COS 2018. Foram realizadas diversas tentativas de classificação com 7 classes, mas por duas classes terem muitas poucas áreas, o algoritmo confundia-se desta forma optou-se por agrupá-las em outra classe, ficando com 5 classes.

Terminando os últimos passos da classificação, é essencial executar a avaliação de exatidão, ou accuracy assessment, para ver se a classificação foi boa ou má e sabendo que se for inferior a 0,75 teria de efetuar este processo novamente. Para executar esta avaliação, utilizou-se na *Classification Tools*, a ferramenta *Accuracy Assessment* onde se introduz como input as áreas de treino guardadas pelo ArcGis Pro quando se conclui a classificação, manteve-se o número de pontos aleatórios e correu-se a ferramenta, onde se obteve a estatística Kappa e a matriz de erro ou de confusão.

4- Resultados

4.1-Cálculo do NDVI para Sentinel/Landsat

O NDVI (Normalized Difference Vegetation Index) é um índice em que o valor do mesmo resulta do cálculo da diferença da banda infravermelha próxima (NIR) e da banda vermelha (RED). O resultado varia entre -1 (ausência de vegetação) e 1 (elevada densidade de vegetação ativa). Sendo que a primeira classe da legenda corresponde aos valores mais altos, que apresentam uma elevada refletância sendo resultantes de uma vegetação fotossinteticamente ativa. Os valores inferiores a 0 não têm valor ecológico, normalmente este valor corresponde a territórios artificializados. Os valores entre 0 e 0,2, normalmente correspondem a solos expostos. Se o valor ultrapassar os 0,6, este é considerado muito alto, ou seja, altamente fotossintético.

Para calcular este índice foram utilizadas quatro imagens satélites recolhidas, do Sentinel dia 22/02/2020 e dia 11/07/2020 e do Landsat 9/07/2020 e 23/02/2020. Como já foi referido anteriormente, a finalidade é comparar a variação da cobertura vegetal consoante a época do ano (inverno/verão) entre as duas imagens satélite.

Os resultados obtidos do Landsat 8 estão representados na Figura 3, para inverno e verão respetivamente. Os valores obtidos no NDVI de inverno foram como era esperado, isto é, haver uma menor atividade fotossintética em relação à imagem do verão. Isto deve-se ao simples facto, de que no Inverno a radiação solar que chega à superfície terrestre é menor, por isso a atividade fotossintética é reduzida. E o comprimento das ondas eletromagnéticas obtidas pelas bandas sensor do satélite (OLI) como é lógico também será menor. O valor maior obtido foi 0,53 e o valor menor foi -0,07. Os valores presentes na classe -0,07 e 0 correspondem no fundo ao rio

Minho, isto porque a água absorve a banda NIR e por isso esta apresenta um valor nulo. Os valores entre 0 e 0,1 corresponde a construções, que apesar de aparentarem serem poucas no fundo estão escondidas pela vegetação.

Na imagem de Verão é possível assimilar a diferença que é apresentada entre a de inverno, isto porque a quantidade de verdes é muito maior, porque a atividade fotossintética no Verão também é elevada devido a uma maior incidência da radiação solar na superfície terrestre. Esta imagem apresenta como valor mais alto 0,62 e como valor menor -0,03

Relativamente aos valores obtidos do Sentinel no inverno, o valor mais elevado foi 1 (0,997) e o valor mais baixo -0,81. Estes valores poderão justificar-se pelo facto de haver maior precipitação o que permite que a vegetação da estação manter-se saudável e além disso, cresce mais vegetação rasteira que também acaba por refletir mais NIR e quanto ao valor mais baixo, poderá ser pelo facto que no inverno parte da vegetação não será dessa estação, ficando caducas, não tendo copa para refletir a radiação e permitindo que haja uma maior refletância da luz vermelha nas edificações, e esta fique mais aparente. No entanto, as classes mais aparentes são entre os 0,4 a 0,8 e não tanto os 0,8 a 1.

No que toca ao verão, o valor mais elevado registado foi 0,95 e o valor mais baixo foi de -0,27. Comparado ao inverno, pode-se observar que há uma área bastante ampla com tons de amarelo, ou seja, a classe entre os 0,2 e 0,4, o que está relacionado com a vegetação não tão saudável e provavelmente em condições de stress por seca. No entanto existe mais vegetação da classe 0,8 a 1 do que no inverno, mas essencialmente a sul, na proximidade dos limites administrativos do concelho, provavelmente por conter mais vegetação desta estação e das temperaturas mais elevadas e ainda perto dos rios.

Quanto ao valor mais baixo, este é mais positivo que no inverno, o que poderá ser explicado pela vegetação desta estação ser de copas de maior dimensão que cobre mais território, podendo refletir a radiação antes que esta incida no solo artificializado, o que justifica a quantidade de vegetação saudável. Ainda na imagem do inverno, é de ressaltar que as estradas e áreas mais urbanizadas estão mais visíveis do que no verão.

Nos índices ambientais, foi possível observar discrepâncias entre os índices feitos em cada satélite, mesmo que as imagens retiradas em ambos correspondam às mesmas estações de ano e em dias muito próximos. A hipótese mais plausível para explicar este facto é a diferença na resolução espacial que generaliza mais, não discrimina tão bem diferenças na vegetação e solo urbano como no caso do Sentinel. Foram possíveis ver grandes diferenças entre os máximos e mínimos atingidos sendo bem menores no Landsat, e consequentemente nas classes não tendo valores acima dos 0,8 que determinaria que houvesse vegetação muito saudável ou vegetação altamente fotossintética.

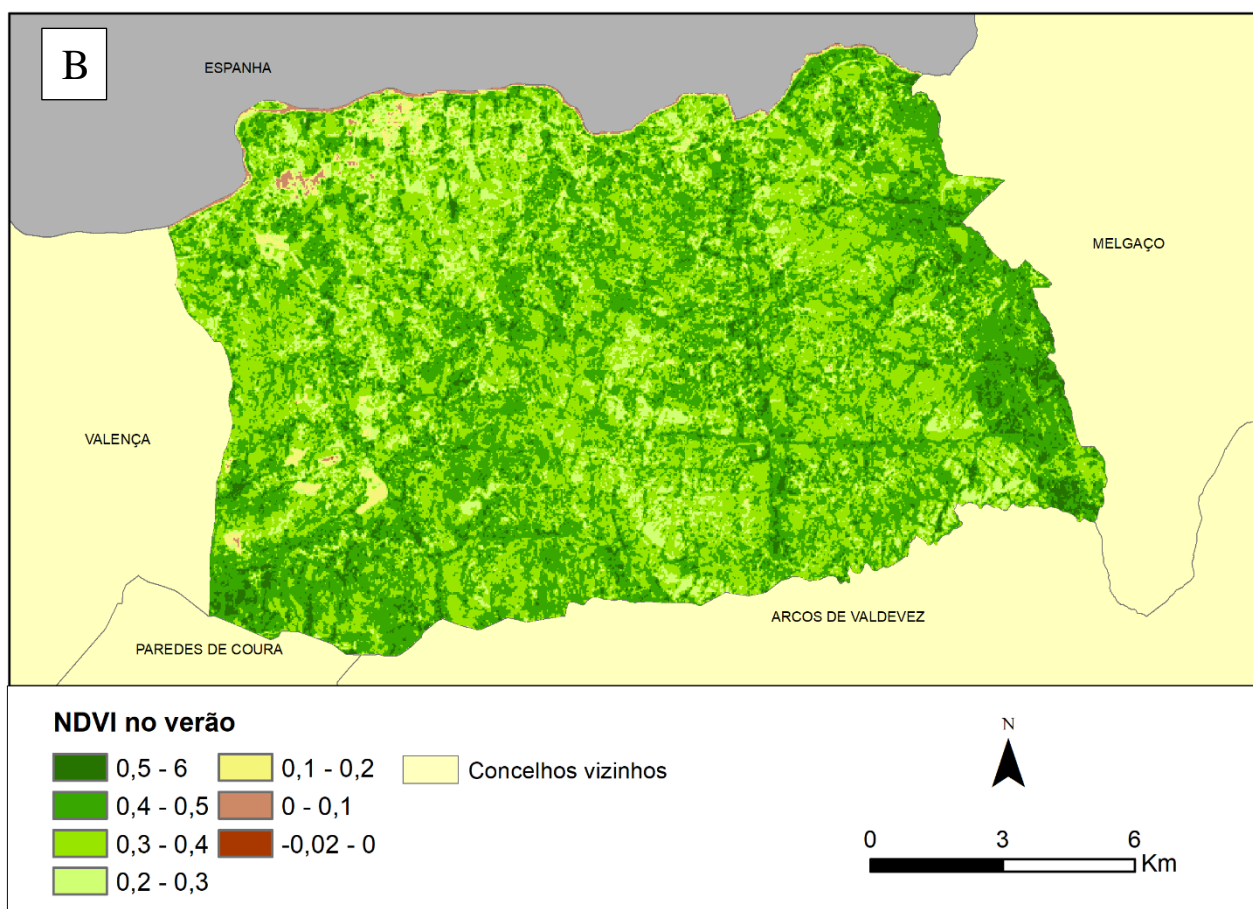
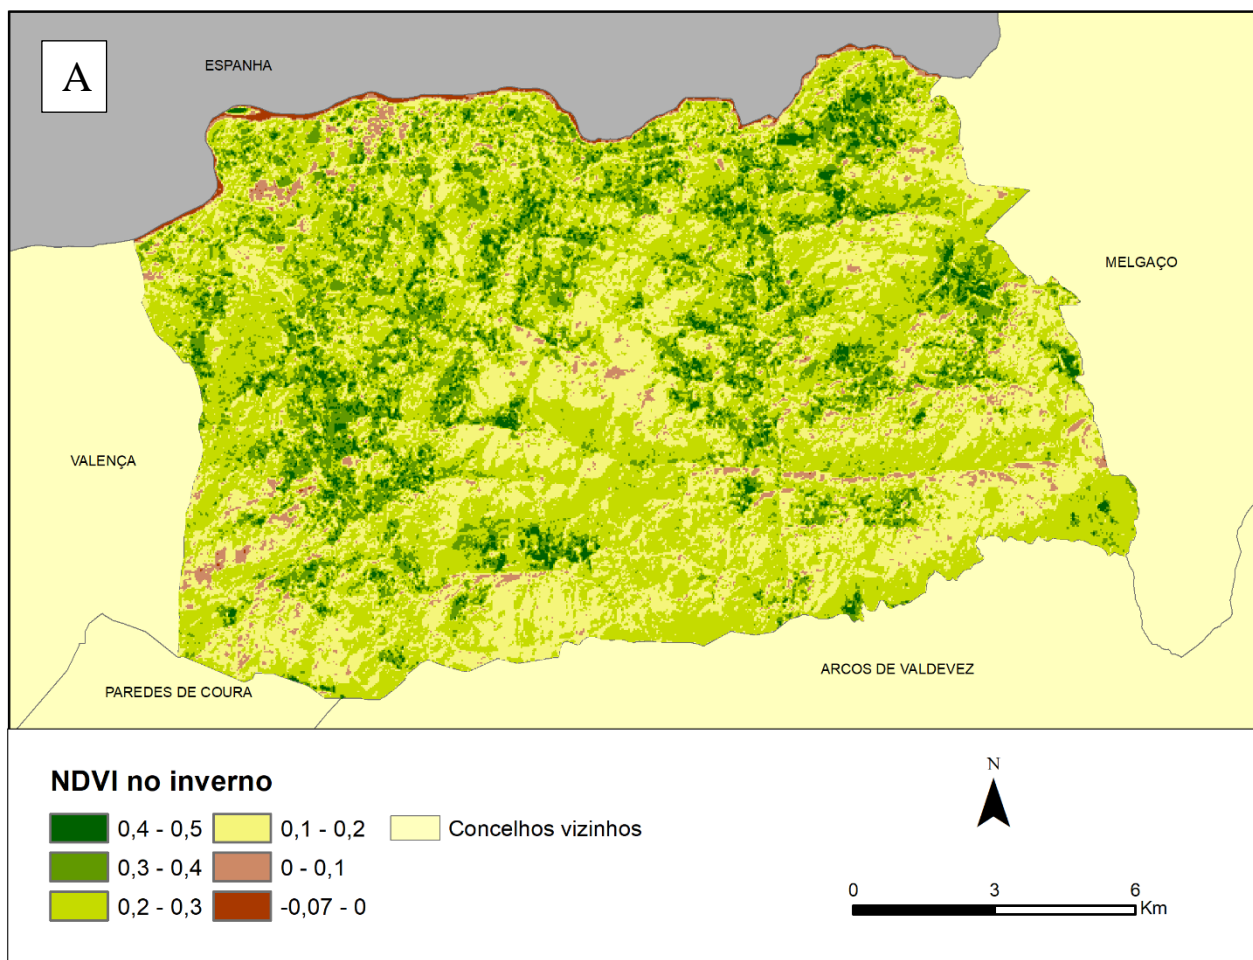


Figura 3 – A) NDVI de inverno proveniente de imagens Sentinel; B) NDVI de verão proveniente de imagens Sentinel.

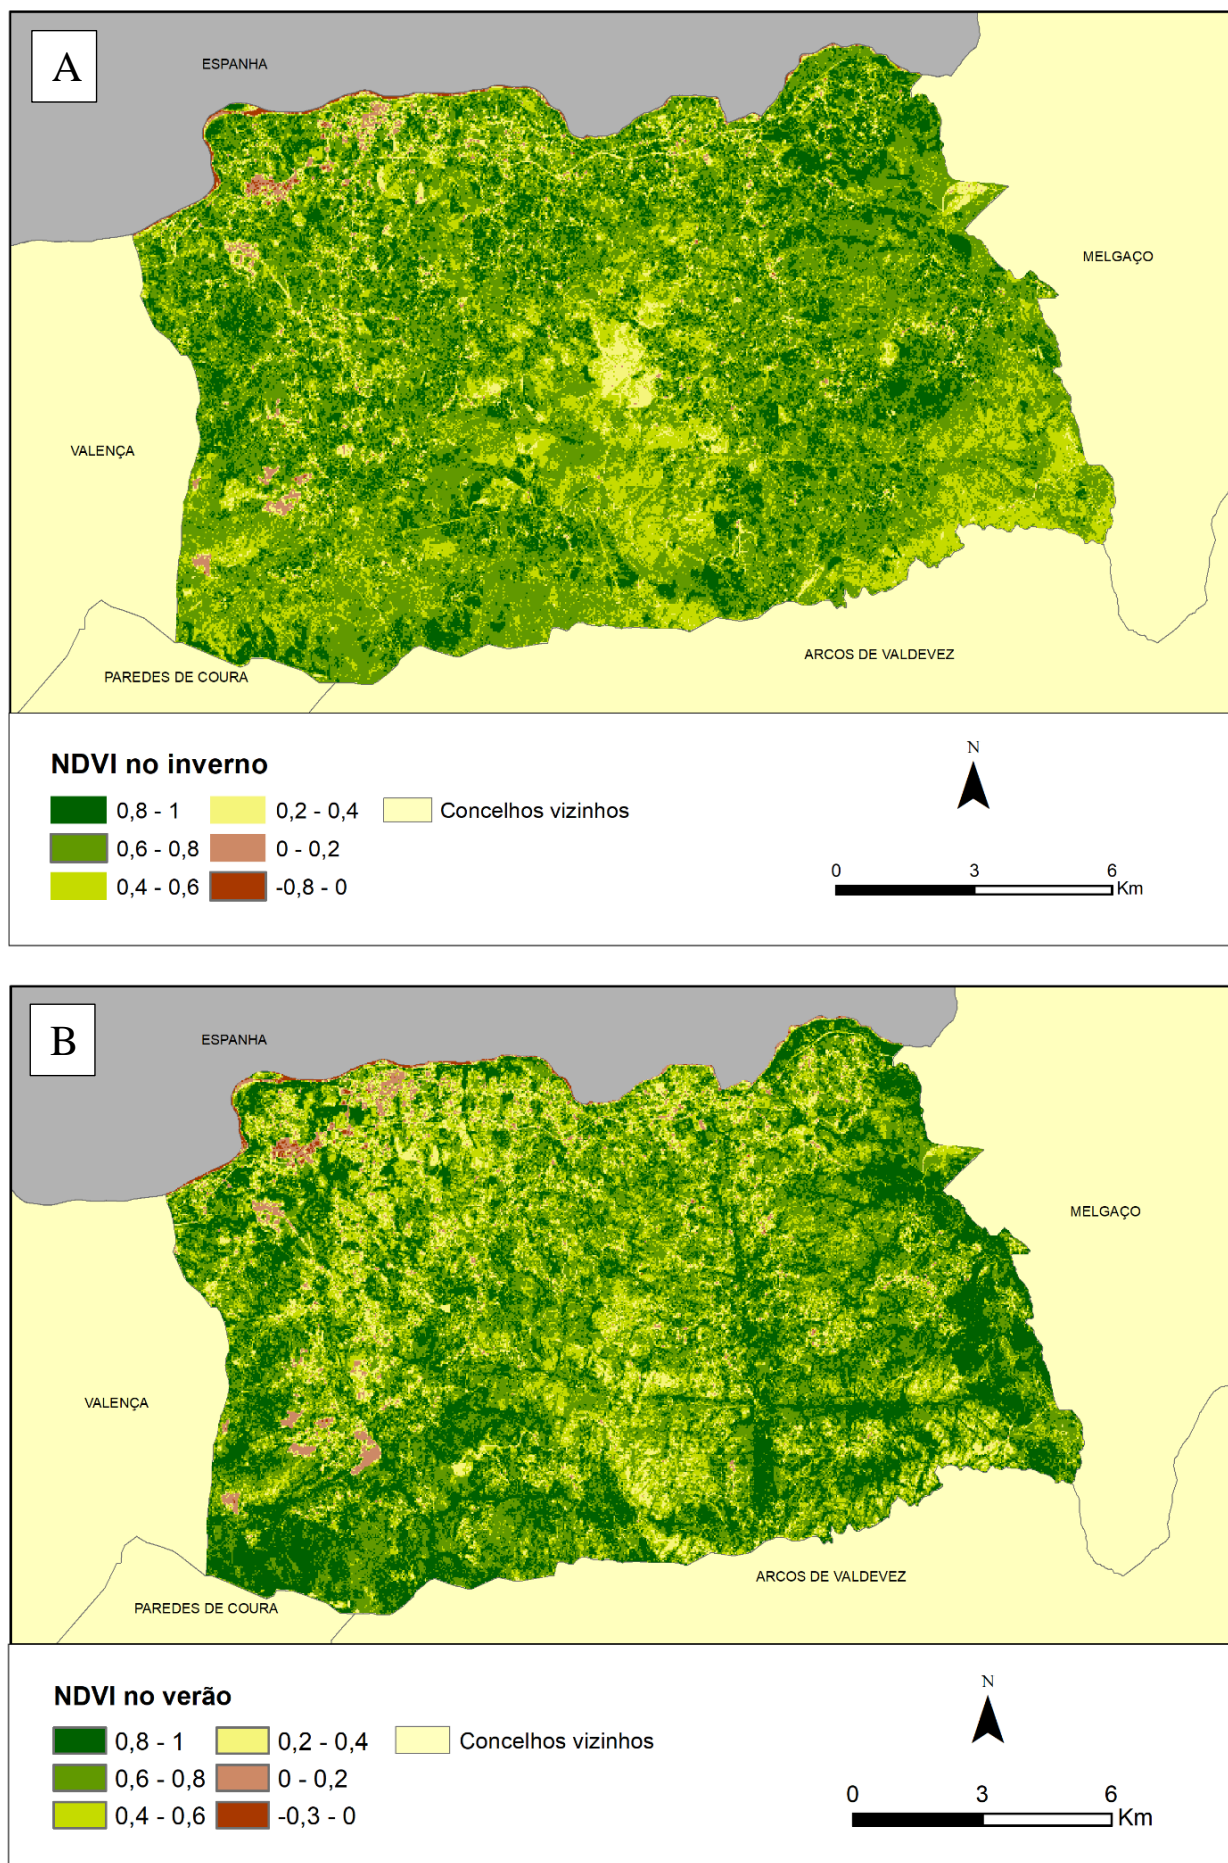


Figura 4- A) NDVI de inverno proveniente de imagens Landsat; B) NDVI de verão proveniente de imagens Landsat.

4.2- Classificação de imagem

A classificação de imagem tem como objetivo a substituição da análise qualitativa da imagem por técnicas quantitativas, para que se possa melhorar a identificação de cada elemento contido na imagem. Esta corresponde a um processo composto por várias etapas em que primeiramente é necessário fazer uma análise multiespectral da imagem e posteriormente aplicar regras de decisão estatísticas. Isto de modo, a possibilitar uma identificação do tipo de ocupação do solo contido em cada pixel. Para esta decisão, é necessário ou usar o processo baseado nas características espectrais dos pixels ou o processo baseado na geometria, tamanho e tipo de dados (domínio espectral).

Para esta classificação foi aplicado a classificação baseada no pixel, em que se agrupou de forma automática todos os píxeis de uma imagem contidos num determinado conjunto de ocupação do solo, como por exemplo: vegetação, territórios artificiais, água, entre outros.

O método usado para fazer esta classificação foi a supervisionada, aquela que é necessária a intervenção por parte do produtor. Como foi referido acima, procede-se a uma análise espectral dos píxeis da imagem. De seguida, cria-se os conjuntos de treino, isto, onde estão contidas as classes dos píxeis que foram distinguidos com propriedades espectrais semelhantes, e avaliando a separabilidade dos dados, isto é, se nenhuma classes espectrais se sobrepõem à outra. Este conjunto de treinos criados servirão para treinar o algoritmo a reconhecer, pois com base na informação o algoritmo executa a classificação de toda a imagem.

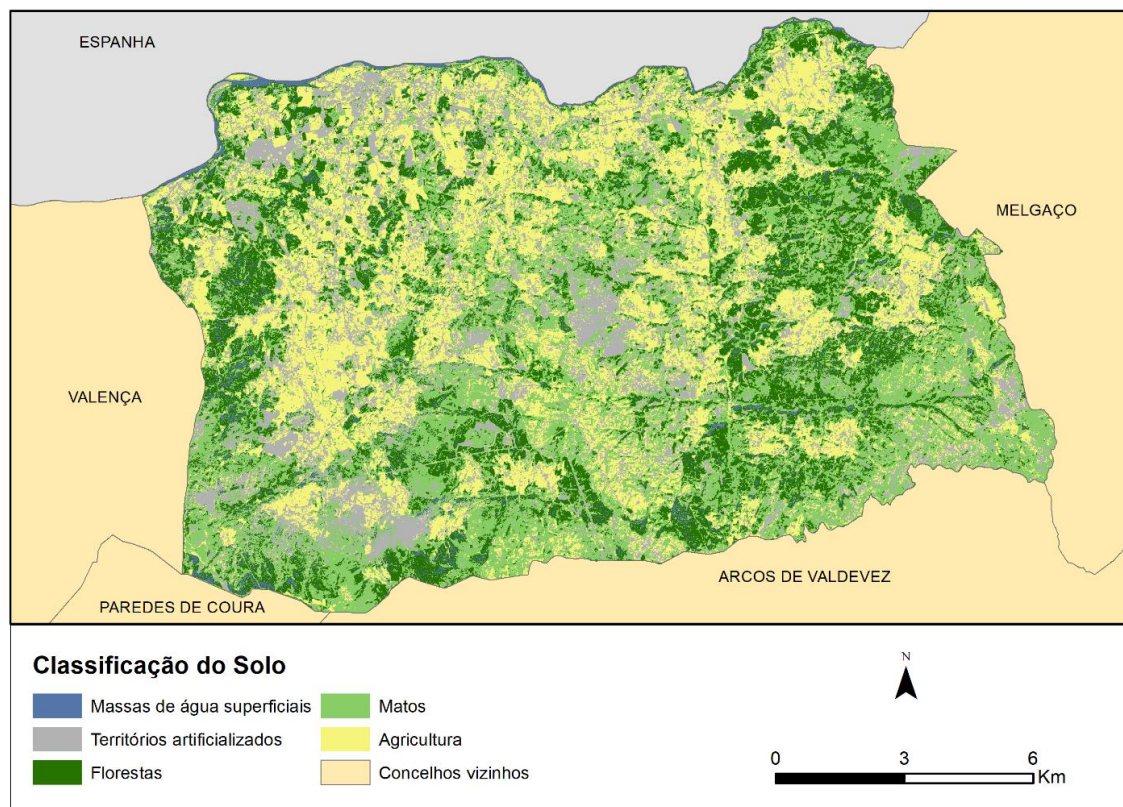


Figura 5 - Classificação supervisionada da imagem de inverno.




Figura 6- Imagem de combinação RGB de inverno.

Após a correta execução do método de classificação supervisionada baseada no pixel, pode-se aferir que ao nível dos resultados das 5 classes obtidas para a imagem de inverno, existe um predomínio da agricultura, florestas e matos. Este resultado é espelho da região onde se encontra a área de estudo, marcadamente com baixos valores de concentração populacional, em oposição com as elevadas áreas agrícolas, ou não ocupadas, como é possível observar na combinação RGB da figura 6.

Neste seguimento surgem os territórios artificializados, que englobam não só toda a área construída, como também as estradas. Pode-se identificar para além das construções, uma parcela significativa deste tipo de área para possivelmente a existência de algumas pedreiras e espaços desmatados ou expostos/nus. Neste caso é também possível identificar na maioria do território os cortes feitos no terreno pelas vias de transito.

Da mesma forma pela imagem classificada não se permite fazer uma concreta discriminação dos rios (massas de água superficiais), pois estes são de pequena dimensão e também muitas vezes circundados por muita vegetação, logo muito difíceis de distinguir a esta escala de tratamento. Apenas se destacam pequenas parcelas desse curso de água como é o caso do rio Minho e Mouro.

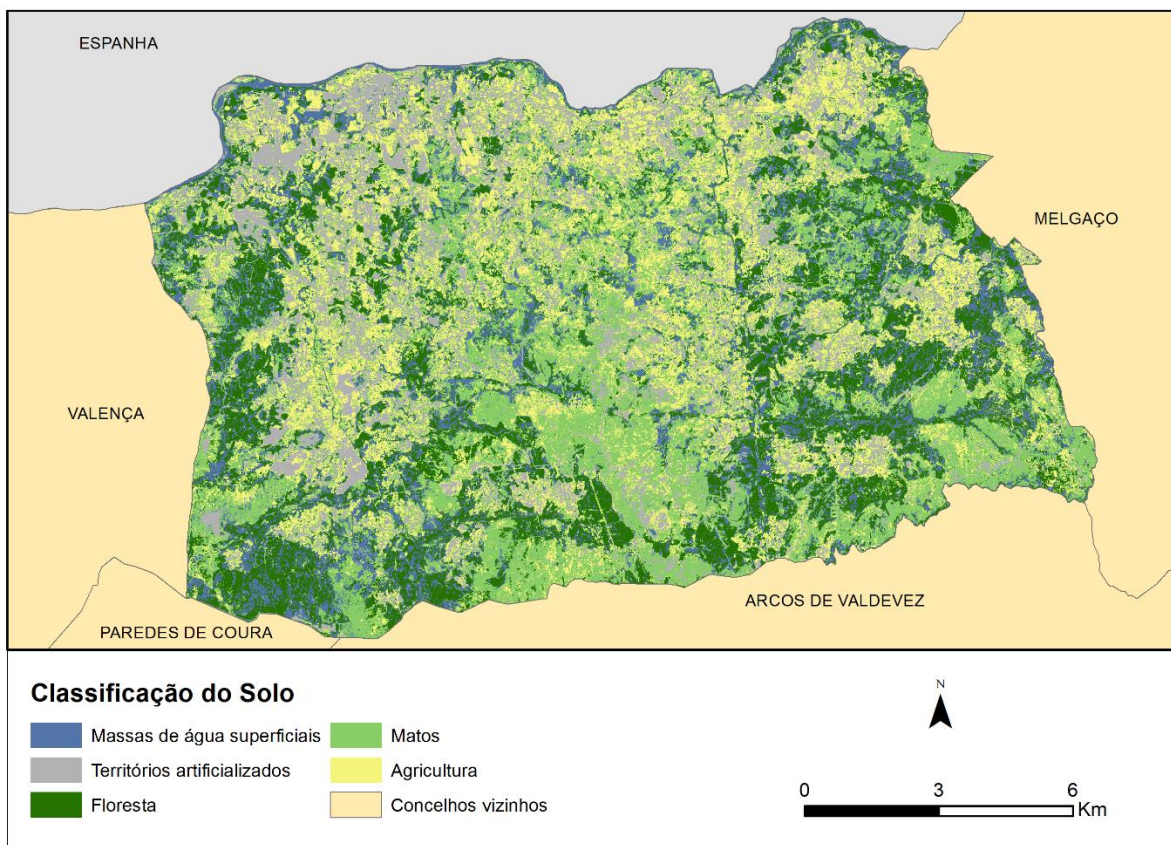


Figura 7 - Classificação supervisionada da imagem de verão.



Figura 8 - Imagem de combinação RGB de verão

Comparativamente com imagem anterior, verificam-se algumas diferenças nos resultados obtidos. Desde logo uma clara predominância de áreas classificadas como floresta e também matos. Nesta imagem, a agricultura quase não é representada devido à confusão do algoritmo entre esta classe e a classe matos como é perceptível na figura 7.

No que diz respeito aos territórios artificializados, por oposição à imagem anterior, verifica-se um nível de pormenor inferior, sendo apenas perceptível algumas estradas e de algumas edificações concentradas relacionadas a aglomerados populacionais presentes no concelho de Monção.

A presença de corpos de água é significativa, apesar de esta não se verificar na realidade (figura 8), pois este erro está relacionado com a maior densidade de vegetação que é visualizada com um píxel de cor muito semelhante com o preto. Igualmente os corpos de água são representados por cores mais escuras, ou seja, características espectrais semelhantes às da floresta. Com isto, o algoritmo tem tendência a confundir estas duas classes distintas. Apenas é visível apenas o rio Minho e uma parcela muito restrita no rio Mouro e Gadanha, não pela sua cor real (azul) mas sim pela linha de vegetação que delimita estes cursos de água.

4.3- Avaliação da Exatidão da Imagem

Após a realização da classificação supervisionada é necessário verificar quais os níveis de perfeição de todo o processo. Nesse sentido é calculada a exatidão através da análise das matrizes de erro ou confusão. Estas são importantes para comparar, para cada classe, a relação entre os pixéis identificados automaticamente, com aqueles realizados com as áreas de treino.

Na avaliação do resultado importa notar que após obter as tabelas de erro, vários valores são possíveis aferir, desde logo, os totais de cada linha dizem respeito aos produtos da classificação. Os totais das colunas representam os dados de referência (verdade terreno), e por fim os elementos da diagonal serão os elementos classificados corretamente. Como erros na classificação (comissão e omissão) ficam todos valores fora da diagonal. A fórmula de cálculo da exatidão global é a seguinte:

$$\text{Exatidão Global} = \frac{\sum \text{Elementos da diagonal}}{\text{Número total de amostras}}$$

Outro parâmetro muitas vezes utilizado para analisar os resultados obtidos pela classificação supervisionada é a **estatística Kappa**. Esta define-se pela medida da diferença entre uma classificação supervisionada e uma classificação completamente aleatória, resultando desta a concordância real dos dados. É de se destacar que se se obtiver um valor inferior a 0,4 considera-se como muito pobre, ou seja, uma classificação incorreta, de 0,4 a 0,75 é considerada médio, mas não muito fiável e por fim acima de 0,75 define-se como uma concordância muito boa, isto é uma classificação boa que se poderia usar para elaborar um mapa de uso e ocupação do solo. O algoritmo aplica-se através da seguinte formula:

$$Kappa = \frac{Exatidão Observada - Concordância hipotética}{1 - Concordância hipotética}$$

Para as classificações realizados podemos aferir que pela aplicação do algoritmo de calculo do erro ambas as imagens obtiveram valores acima do mínimo exigido (0,75). Para a classificação executada para o verão, atingiu-se 0,8 enquanto na segunda aplicação se obteve 0,9 de exatidão dos dados. Importa ressaltar que para se atingirem estes valores foi necessário executar variadíssimas vezes melhorias nas classes de treino para assim reduzir os pequenos erros ao nível dos píxeis com semelhanças de valores.

ClassValue	Massas de água superficiais	Teritórios artificializados	Floresta	Matos	Agricultur	Total	U_Accuracy	Kappa
Massas de água superficiais	52	0	0	0	0	52	1	0
Teritórios artificializados	0	69	0	0	0	69	1	0
Floresta	0	0	135	30	0	165	0,818181818	0
Matos	0	0	3	94	0	97	0,969072165	0
Agricultura	0	0	0	7	110	117	0,94017094	0
Total	52	69	138	131	110	500	0	0
P_Accuracy	1	1	0,978261	0,717557	1	0	0,92	0
Kappa	0	0	0	0	0	0	0	0,897007

Figura 9 - Matriz de erro relativa ao inverno.

Quanto à matriz relativa a fevereiro, apenas tivemos píxeis mal classificados nas classes floresta, matos e agricultura, onde na floresta apenas 3 píxeis foram mal classificados pelo produtor, mas o algoritmo confundiu 30 píxeis com os matos, tendo assim uma exatidão do produtor de 0,97 e do utilizador de 0,81. Na classe matos foram mal classificados pelo produtor 30 píxeis que ficaram na floresta e 7 píxeis foram confundidos com agricultura, e pelo utilizador apenas 3 píxeis foram confundidos com Floresta, tendo uma precisão de produtor de 0,71 e de utilizador de 0,96. Por fim, na classe da Agricultura apenas houve erros de comissão sendo que apenas 7 píxeis mal classificados, resultando numa precisão de utilizador de 0,94 e de produtor de 1. As restantes classes foram bem classificadas tanto pelo produtor como pelo algoritmo.

Nesta tabela, ainda obtemos a exatidão global desta classificação que totaliza os 0,92 e uma estatística Kappa de 0,89, ou seja, uma classificação bastante boa já que em ambas avaliações estão próximas do máximo (1) e acima de 0,75.

ClassValue	Massas de água superficiais	Teritórios artificializados	Floresta	Matos	Agricultura	Total	U_Accuracy	Kappa
Massas de água superficiais	27	0	10	12	0	49	0,551020408	0
Teritórios artificializados	0	41	0	1	0	42	0,976190476	0
Floresta	7	0	178	2	2	189	0,941798942	0
Matos	0	4	1	124	13	142	0,873239437	0
Agricultura	0	0	0	9	69	78	0,884615385	0
Total	34	45	189	148	84	500	0	0
P_Accuracy	0,794117647	0,911111111	0,941798942	0,837837838	0,821428571	0	0,878	0
Kappa	0	0	0	0	0	0	0	0,833474

Figura 10 - Matriz de erro relativo ao verão.

Quanto à matriz de confusão de julho apresenta erros em todas as classes. A classe com mais erro é as massas de água superficiais, em que o algoritmo teve uma exatidão de 0,55 classificando erroneamente 10 píxeis na classe da floresta e 12 na classe dos matos e quanto à exatidão do produtor, apenas 7 píxeis foram mal classificados na classe da floresta, resultando numa exatidão de 0,79. Nos territórios artificializados, teve pouco erro mas teve erros tanto de comissão como de omissão, o algoritmo classificou errado 1 píxel na classe matos, ficando com 0,97 e quanto à qualidade das áreas de treino, classificou-se mal 4 píxeis na classe matos, restando uma exatidão de 0,91 do produtor. Relativamente à floresta, mediante as classes de treino executadas, a exatidão do produtor foi de 0,94, tendo mal classificado 10 píxeis na classe de massas de água superficiais e 1 na classe matos e a exatidão do utilizador totalizou os 0,94, classificando erroneamente 2 píxeis nos matos e outros 2 na classe agricultura. A classe matos foi bastante confundida com as restantes classes, totalizando uma exatidão de produtor de 0,83 e de utilizador de 0,87. Por fim na classe da agricultura houve mais erro de omissão que de comissão, sendo que a exatidão do produtor foi de 0,82, a mais baixa comparado às restantes, onde houve confusão essencialmente com os matos, mas também com a floresta e obteve-se uma exatidão de utilizador de 0,88, tendo mal classificado 9 píxeis na classe matos. Esta tabela ainda indica a exatidão global que totalizou os 0,87 e a estatística Kappa com 0,83.

5- Conclusão

Em virtude dos aspetos abordados, pode-se concluir que após a realização deste estudo comparativo entre as imagens, classificações e índice realizados, permitiu adquirir conhecimentos práticos sobre possíveis análises remotas do terreno.

Na análise do índice ambiental foram perceptíveis grandes diferenças nos resultados obtidos entre os dois satélites abordados a nível da resolução espacial. Dado que, o satélite

Landsat tem uma menor resolução, logo este tem menos detalhe e generaliza a informação, por isso apresenta uns valores máximos, mínimos e uma representação distinta do Sentinel, que detém um grau de detalhe superior.

Na comparação de NDVI de diferentes estações, é também possível detetar disparidades nos dados obtidos. Dependendo de diferentes situações climáticas e níveis de humidade, o NDVI pode sofrer alterações inesperadas. Estas podem estar relacionadas com o nível de precipitação e humidade do solo, pois em anos com elevados valores destes dois fatores a refletância será menor dado a maior quantidade de água existente. Pelo inverso também se pode aferir que em anos em que se verifiquem défices hídricos os valores de refletância sobe quando associado ao solo, pois o solo seco reflete mais. Já no caso da vegetação, quando afetado por fatores hídricos, dados que não conseguem realizar o processo de fotossíntese (stress hídrico) os valores de refletância para a banda NIR são inferiores.

Quanto à classificação realizada, pode-se afirmar que as classes definidas estão diretamente relacionadas com a tipologia de ocupação de solo. Neste processo, detetaram-se visualmente alguns erros derivados de semelhanças espectrais de certos píxeis correspondentes a classes distintas, principalmente apreendidos na comparação entre os resultados.

Os erros identificados foram confirmados através das matrizes de erro, que permitiram obter uma descrição mais detalhada das classes que alcançaram menor exatidão e demonstram, ao mesmo tempo, qual dos intervenientes na classificação foi responsável pelos mesmos.

6- Bibliografia

- Câmara Municipal de Monção (s.d), disponível em: <http://www.cm-moncao.pt/>
- Câmara Municipal de Monção (2009). Plano Diretor Municipal: Caracterização Física. 49 pag.
- Lira, C., Amorim, A., Silva, A. N., Taborda, R., do Guia Técnico, C., Lira, C., ... & Taborda, R. (2016). Sistemas de Informação Geográfica: Análise de Dados de Satélite. Lisboa, Portugal: DGRM.